

## 딥러닝 기반 교량 구조물 다중 손상유형 탐지 시스템\*

김영남<sup>01</sup> 배현재<sup>2</sup> 김영민<sup>3</sup> 장규진<sup>1</sup> 김진평<sup>1</sup><sup>1</sup>차세대융합기술연구원 컴퓨터 비전 및 인공지능 연구실<sup>2</sup>성균관대학교 소프트웨어학과<sup>3</sup>인천대학교 경제학과

hwarangmoon@snu.ac.kr, jason0425@snu.ac.kr, winston1214@naver.com, gjjang@snu.ac.kr, jpkim@snu.ac.kr

## Deep Learning based Multiple Damage Type Detection System for Bridge Structures

YoungNam Kim<sup>01</sup> HyunJai Bae<sup>2</sup> YoungMin Kim<sup>3</sup> GyuJin Jang<sup>1</sup> JinPyung Kim<sup>1</sup><sup>1</sup>Computer Vision and Artificial Intelligence laboratory, Advanced Institute of Convergence Technology<sup>2</sup>Department of Computer Science and Engineering, Sungkyunkwan University<sup>3</sup>Department of Economics, Incheon National University

## 요 약

현재 교량 등의 국내 고속도로 구조물 안전 점검 방식은 훈련받은 검사자가 현장에서 직접 측량 도구를 통해 육안으로 판단하는 방식으로서, 객관성과 효율성에서 문제점을 드러내고 있다. 이를 보완하기 위해 최근 딥러닝을 이용한 구조물 손상탐지 연구들이 진행되고 있지만 데이터 세트 부족 등의 이유로 인하여 균열을 제외한 나머지 손상유형 탐지에 관한 연구는 아직 부족한 실정이다. 본 연구에서는 CNN 계열의 딥러닝 모델과 영역 분할 알고리즘을 이용한 교량 구조물 다중 손상유형 탐지 시스템을 제안한다. 먼저 일반 균열, 망상 균열, 백대, 부식, 누수의 5가지 교량 구조물 손상유형을 정의하고 VGGNet 기반의 CNN 모델로 학습시킨 후, Watershed 알고리즘을 이용해 원본 교량 구조물 이미지의 배경 영역과 교량 영역을 분할했다. 5가지 교량 구조물 손상유형의 최종 탐지는 분할된 교량 영역에 대해서 수행되며 평균 손상탐지 정확도 94.48%의 성능을 보였다.

## 1. 서 론

현재 국내 고속도로의 구조물은 대형화 및 그 숫자가 큰 폭으로 늘어나고 있으며, 제 1·2종 시설물 가운데 공용된 지 30년 이상이 지난 노후화 시설물이 증가함에 따라 기존 인력 위주의 점검 방식은 한계점이 뚜렷이 발생하고 있다. 2018년 국토교통부에서 발표한 자료에 따르면 30년 이상 경과한 노후 시설물은 2017년 약 2,600개 수준에서 2024년에는 9,000개, 2029년에는 23,000개로 그 수량이 약 3.5배에서 9배로 급증할 것으로 예상된다. 이에 따라 구조물 유지관리 비용 또한 2014년에서 2020년까지 연평균 14% 수준으로, 점검 및 진단에 드는 비용은 약 3배 가까이 증가할 것으로 관측된다 [1].

이처럼 교량 등의 국내 구조물이 대형화되고 노후 시설물이 급증하는 추세에서 기존 구조물 유지관리 방식의 한계를 극복하기 위한 구조물 안전진단 기술의 지능형 자동화의 필요성이 증대되고 있다 [2].

기존 구조물 안전 점검 방식은 인력 위주의 점검으로서, 훈련받은 검사자가 현장에서 각종 손상유형의 손상 여부를 직접 육안으로 판단하는 방식이다. 하지만 검사자에 따라 손상 여부가 주관적으로 결정된다는 점, 당일 날씨 등 주변 환경에 의해 검사자의 판단 결과가 영향을 받을 수 있다는 점 등이 문제점으로 꼽힌다. 최근 들어 이런 인력 중심의 구조물 점검을 탈피하고 첨단기술 중심으로의 안전진단 기술 패러다임 전환을 위해 많은 연구가 이루어지고 있는데, 그 중 대표적인 방식 중 하나가 다양한 영상처리기술을 활용한 구조물 손상탐지 방법이

다. 또한 GPU(Graphics Processing Unit)로 대변되는 컴퓨팅 파워의 비약적인 발전으로 인해 Canny Edge Detector와 같은 과거 전통적인 에지 검출 알고리즘 기반 방식이 아닌, 딥러닝 기반 방식의 영상처리기술을 적용한 구조물 손상탐지 연구가 활발히 진행되고 있다. 하지만 딥러닝 기반 구조물 손상탐지와 관련된 국내 선행 연구들은 주로 콘크리트 구조물에서 발생하고 있는 균열탐지에 집중되고 있으며, 상대적으로 균열 외 다른 손상유형 탐지에 관한 연구는 아직 많이 부족한 실정이다.

본 논문에서는 CNN(Convolutional Neural Network) 계열 딥러닝 모델을 이용한 교량 구조물 다중 손상유형 탐지 시스템을 제안한다. 손상유형은 일반 균열, 망상 균열, 백대, 부식, 누수 총 5가지 유형으로 구분했으며 실험은 한국도로공사 도로교통 연구원에서 드론으로 기촬영된 360도 영상데이터에서 수집된 교량 손상데이터를 이용했다.

본 논문의 구성은 다음과 같다. 2장에서는 제안된 교량 구조물 다중 손상유형 탐지 시스템의 구성에 관해 기술하고 3장에서는 5가지 손상유형 데이터셋 구축 설명 및 제안 시스템의 실험 결과를 보인다. 마지막으로 4장에서는 결론과 향후 연구 방향에 관하여 기술한다.

## 2. 교량 구조물 다중 손상유형 탐지 시스템

본 논문에서는 5가지 교량 구조물 손상유형 분류 및 손상탐지를 위해 CNN 모델과 Watershed 알고리즘을 이용한 다중 손상유형 탐지 시스템을 제안하였으며 구성도는 그림 1과 같다. 먼저 VGGNet 모델을 사용하여 5가지 교량 구조물 손상유형을 학습시킨 후, 실제 기촬영된 교량 이미지에서 손상유형 탐지를 수행하기 위하여 Watershed 알고리즘을 이용해 배경 영역과

\* 이 논문은 행정안전부 극한재난대응기술개발사업의 지원을 받아 수행된 연구임(2020-MOIS31-014)

교량 영역을 분할하였다. 5가지 교량 손상유형 탐지는 분할된 교량 영역에 대해서 슬라이딩 윈도우 방식을 사용해 실험을 진행하였다.

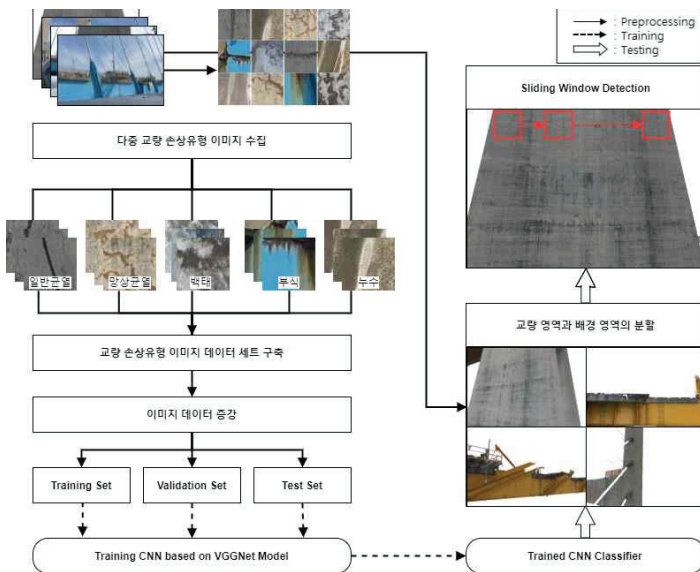


그림 1. 교량 구조물 다중 손상유형 탐지 시스템 구성도

## 2.1 교량 구조물 다중 손상유형 분류모델

최근 딥러닝을 이용한 영상처리가 여러 분야의 연구들에서 우수한 성능을 보이고 있지만, 각종 구조물 손상유형에 대한 이미지 분류 연구는 정확도가 상대적으로 낮고 상기 기술한 바와 같이 분류 대상도 균열 손상유형으로 한정되어있는 경우가 많다.

본 논문에서는 5가지 교량 구조물 손상유형을 학습시키기 위해 VGGNet 모델을 사용하고 학습데이터에 맞게 모델을 최적화시켰다. VGGNet은 2014년 ILSVRC 대회에서 GoLeNet에 이어 2위를 차지한 CNN 모델로서 간결한 구조와 사용 편의성의 장점으로 인하여 많은 이미지 분류 연구에서 활용되었다 [3]. VGGNet 연구팀은 모델 깊이의 영향을 분석하기 위해 3×3의 매우 작은 필터를 가진 컨볼루션 레이어(Convolution Layer)를 여러 층 쌓아 깊게 만들어서 깊이의 영향력을 보였는데, 총 6개의 구조(A, A-LRN, B, C, D, E)를 만들어서 성능을 비교했다. 그 결과 모델의 깊이가 구조 A의 11층에서 구조 E의 19층까지 깊어질수록 이미지 분류 오류율이 감소하는 것을 보였으며, VGGNet 이전 기존 State Of the Art 연구에 사용되었던 7×7 필터 하나 대신 3×3 필터 3개를 사용하였을 때 모델을 학습시키기 위한 총 파라미터 개수가 81% 정도 더 절감됨을 증명했다. 일반적으로 망이 깊어질수록 학습에 필요한 파라미터 수가 증가하고 그에 따라 연산속도의 저하와 함께 과적합의 위험이 커지는데, VGGNet 연구팀의 구조 실험은 결과적으로 망의 깊이를 늘리면서도 모델 학습에 필요한 총 파라미터 개수는 줄일 수 있었다. 또한 심층 신경망을 학습시킬 때 발생할 수 있는 기울기의 소실 문제를 해결하기 위해 11층 구조의 A 모델에서 학습된 결과를 다음 B, C, D, E 모델들을 구성할 때 가져와서 더 깊은 층의 파라미터 초기화에 이용하였다.

본 논문에서는 5가지 교량 구조물 손상유형 학습데이터를 훈련시키기 위한 VGGNet 모델 구조를 13층에서 19층까지 증가시키면서 각 층의 학습 하이퍼 파라미터들을 최적화시켰으며 모델 학습 결과와 최종 손상탐지 실험에 사용된 모델 구조는 3.2 절에 기술하였다.

## 2.2 교량 영역 분할 알고리즘

본 논문에서는 학습된 VGGNet 기반 다중 손상유형 분류모델을 이용해 드론으로 실제 기촬영된 교량 이미지에서 5가지 교량 구조물 손상유형 탐지 실험을 진행하였다. 교량 이미지의 최대 사이즈가 5472×3648로서 매우 크기 때문에 일반적인 슬라이딩 윈도우 방식으로 손상탐지를 수행할 경우 긴 수행시간이 소요된다. 우리는 이와 같은 문제점을 해결하기 위해 Watershed 알고리즘을 이용해서 이미지 내 배경 영역과 교량 영역을 분할하였다.

Watershed 알고리즘은 영역 기반 영상 분할 알고리즘으로서, 영상 내 픽셀들의 집합을 하나의 지형으로 간주해서 높낮이를 분석한 기법이다 [4]. Watershed 알고리즘에서는 Rainfall 방법과 Flooding 방법을 사용해서 높은 값을 갖는 픽셀들을 워터셰드 라인(WaterShed Line), 낮은 값을 갖는 픽셀들을 국부 최소값(Regional minimum)이라고 표현했다. 먼저 원 영상을 입력받아 색상공간 변환, 잡음 제거, 비선형 확산 및 거리 변환의 전처리를 거친 후 이진화 과정을 통해 각 픽셀 공간을 Watershed와 Minima 지역으로 나눈다. 그런 다음 Rainfall 방법과 Flooding 방법을 선택해서 수행하면 그에 따른 영역 분할이 완성된다. 최종적으로는 배경 영역을 제외한 교량 영역에 대해서만 슬라이딩 윈도우 방식의 교량 손상탐지를 수행함으로써 전체 손상탐지 시간을 단축시킬 수 있다.

## 3. 실험 결과

### 3.1 교량 구조물 손상유형 데이터 세트

본 연구에서는 한국도로공사 도로교통연구원에서 제공받은 교량 구조물 원본 이미지 데이터를 사용하였다. 한국도로공사 도로교통연구원의 원본 이미지 촬영은 서해대교 사장교 구간과 연대교에서 진행되었으며, 본 연구팀은 촬영 원본 이미지 중 5가지 손상유형이 발생한 손상 이미지를 직접 분류해서 원본 데이터베이스를 구축하였다. 또한 손상 부위를 정밀하게 탐색하기 위해 손상 이미지의 크기를 64×64로 조정하고 이미지 반전, 회전, 확대, 축소 및 방향 이동 등의 2차원 변환 기법으로 이미지 데이터 증강작업을 수행하였다. 이를 통해 부족한 학습데이터의 수량을 충분히 확보하고 학습모델의 과적합을 사전에 방지할 수 있다. 교량 구조물 손상유형 데이터 세트의 세부 사항은 표 1과 같다.

표 1. 교량 구조물 손상유형 데이터 세트의 세부 사항

손상유형	학습셋	검증셋	실험셋	원본 해상도
일반 균열	20,000	12,000	8,000	5472×3648
망상 균열	20,000	12,000	8,000	1536×1536
백태	20,000	12,000	8,000	2048×2048
부식	20,000	12,000	8,000	5472×3648
누수	20,000	12,000	8,000	1536×1536
Total	100,000	60,000	40,000	-

### 3.2 교량 구조물 손상유형 분류 및 손상탐지 결과

본 연구에서는 최적의 다중 손상유형 분류모델 학습을 위해 VGGNet 모델 구조를 변경시키면서 실험을 진행하였다. 원래 VGGNet은 227×227 RGB 크기의 이미지를 입력으로 사용하였지만 본 실험에서는 64×64 RGB 크기의 이미지를 입력으로 사

용했기 때문에 합성곱 계층과 완전연결 계층에 사용된 하이퍼 파라미터를 조정할 필요가 있었다. 하이퍼 파라미터 조정은 합성곱 계층 간의 정상적인 연결과 특징맵 출력 및 분류 클래스 개수를 고려해서 결정되었다. 본 연구의 실험 환경 구성은 표 2와 같다.

표 2. 실험 환경





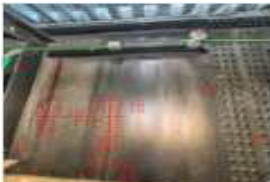
실험 사양	CPU	Intel Core i9-10850K@3.60GHz
	GPU	NVIDIA GeForce RTX 3080
	Memory	32GB
	OS	Window 10
훈련 옵션	Learning Rate	0.0005
	Batch Size	128
	Epochs	100
	Optimizer	Adam

교량 구조물 다중 손상유형 분류모델의 성능평가는 검증 세트와 실험 세트에 대해서 SCCE(Sparse Categorical Cross-Entropy) 손실함수를 이용한 정확도 평가로 진행하였다. SCCE 손실함수는 클래스가 3개 이상인 데이터를 대상으로 사용하는 손실함수로서 실제 클래스의 출력 라벨이 one-hot 형태가 아닌 정수 형태로 제공될 때 사용된다. 예측 라벨은 주로 소프트맥스(Softmax) 함수를 활성화 함수로 해서 계산하며 실제 라벨과 예측 라벨의 두 확률 분포 사이의 유사성을 측정한다. 성능평가 결과는 표 3과 같고 VGG-19 구조의 모델이 준비된 실험 세트에 대해서 99.72%로 가장 우수한 정확도를 보였다.

표 3. 교량 구조물의 다중 손상유형 분류모델 성능평가표

훈련 모델	학습 정확도	검증 정확도	실험 정확도
VGG-13	99.91%	97.39%	97.34%
VGG-16	99.78%	99.77%	99.09%
VGG-19	99.82%	99.74%	99.72%

표 4. 교량 구조물의 다중 손상유형 탐지 결과

다중 교량 손상유형 탐지 예시	
	
일반 균열(정확률: 99.1%)	망상 균열(정확률: 95.7%)
	
백태(정확률: 82.2%)	부식(정확률: 99.8%)
	
누수(정확률: 95.6%)	

교량 구조물의 다중 손상탐지 실험은 한국도로공사 도로교통 연구원에서 기촬영된 서해대교와 연대교의 원본 이미지에 대해서 수행되었으며 그 결과는 표 4로 정리하였다. 교량 손상유형의 손상탐지 정확도는 슬라이딩 윈도우 방식을 통해 탐색할 모든 영역에 대해서 사전에 Ground truth로 사용될 라벨을 부여하고, 학습된 다중 분류모델에 의해 실제 예측된 라벨 중 참값의 비율로 측정되었다. 실험 결과 일반 균열의 손상탐지 정확도는 99.1%, 망상 균열의 손상탐지 정확도는 95.7%, 백태의 손상탐지 정확도는 82.2%, 부식의 손상탐지 정확도는 99.8%, 누수의 손상탐지 정확도는 95.6%의 성능을 보였으며 5가지 교량 손상유형의 평균 손상탐지 정확도는 94.48%로 나타났다.

#### 4. 결론 및 향후 연구계획

본 논문에서는 교량 구조물에서 발생할 수 있는 손상유형을 일반 균열, 망상 균열, 백태, 부식, 누수의 5가지 손상유형으로 정의하고 실제 데이터 세트 구축 및 최적화된 VGGNet 기반 다중 분류모델을 설계하였다. 또한 한국도로공사 도로교통연구원에서 드론으로 기촬영된 실제 교량 구조물 이미지를 대상으로 손상유형 탐지를 수행하기 위해 Watershed 알고리즘을 이용하여 배경 영역과 교량 영역을 분할한 후, 분할된 교량 영역에 대해서 슬라이딩 윈도우 방식으로 다중 손상유형을 탐지하는 시스템을 제안했다.

실험 결과 VGG-19 기반 모델 구조가 분류모델 성능평가에서 가장 뛰어난 정확도를 보였으며 5가지 손상유형에 대해서 94.48%의 평균 손상탐지 정확도를 기록했다. 현재 국내 연구 중에서는 아직 교량 구조물의 다중 손상유형 분류 및 손상탐지에 관한 연구가 부족한 바, 향후 연구에서는 해외 연구 사례를 조사해서 비교 연구를 수행하고 보다 정밀한 교량 영역 분할을 위해 딥러닝 기반의 영역 분할 알고리즘을 전체 시스템에 추가 보완할 예정이다.

#### 참고 문헌

- [1] 한국도로공사 도로교통연구원(2015), “고속도로 교량의 중장기 유지관리 비용 예측을 위한 모델 개발”
- [2] 조준상, 강상규, and 박종철. “서울-세종 고속도로 영상기반 스마트 교량점검 시스템 구축방안.” 대한토목학회 학술대회 (2019): 437-438.
- [3] Simony-an, Karen, and Andrew Zisserman. “Very deep convolutional networks for large-scale image recognition.” arXiv preprint arXiv:1409.1556 (2014).
- [4] Beucher, Serge. “The watershed transformation applied to image segmentation.” Scanning microscopy-supplement- (1992): 299-299.